

* Задача Генерантна (във възупност):

Генерантна във възупност (популация) се нарича във възупността си всички изследвани обекти.

* Задача Случай на изваждане:

Случайният вектор $\vec{X} = (x_1, x_2, \dots, x_n)$ си характеризира и еднакъв разпределение (нр. Gen. (iii. d)) с вероятността об-я на разпределение $F_{\vec{X}}(x)$ се нарича случаената изваждка с размер n . Нагл $x_i \in \vec{X}$ са компоненти на X .

* Задача Моментна оценка:

функцията $\hat{\theta} = \hat{\theta}(\vec{X})$ се нарича статистичка оценка нарица и моментна оценка на θ .

* Задача Ф-я на максималното правдоподобие:

~~Функцията на максималното правдоподобие назираме~~

Функция на максималното правдоподобие назираме (във вид на итогова лъчност) на \vec{X} , т.е.

$$L(\vec{X}, \theta) = \prod_{i=1}^n f(x_i | x_i, \theta).$$

→ Броят на всички изваждки об-я, то
в разпределението $f(x_i | x_i, \theta)$, например
за редица по θ

и то ито конкретна реализация \vec{X} , то об-ято на

$$L(\vec{X}, \theta) = \prod_{i=1}^n f(x_i | x_i, \theta)$$

→ събираемата
лъчност в конкретните
моменти в \mathbb{R}^n

Задача оценка по М.М.Н.:

Самоочевидно $\hat{\theta}(\vec{x})$ не нарица оценка по М.М.Н. на

M, M, N , ако:

$$L(\vec{x}, \theta) = \sup_{\theta \in \Theta} L(\vec{x}, \theta), \text{ т.е. } \Theta \subset$$

множество из варии допустимо за θ .

и Ако $f(x|\theta)$ е грб. по θ , то $\hat{\theta}$ е решение на

$$\frac{\partial L}{\partial \theta} = 0 \Leftrightarrow \frac{\partial \ln L}{\partial \theta} = 0$$

Бережно

Задача оценка по М.М.Н. за $x \sim N(\mu, \sigma^2)$:

Ако $x \sim N(\mu, \sigma^2)$ и \vec{x} е изброка на x . Тогава М.М.Н. за

μ е $\hat{\mu}(\vec{x}) = \bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ (известно грб. σ^2 е изброчно или не).

МНО за σ^2 е:

i) $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n |x_i - \mu|^2$, когато μ е известно

ii) $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}_n|^2$, когато μ не е известно.

Задача оценка по ММН:

Ако X е с.р.сн. и има ф-я на разпределение $F(x|\theta)$,

\vec{x} е изброка на X и $G = (\theta_1, \dots, \theta_s)$.

$E(X^k) = \mu^{(k)}(\theta)$ \rightarrow теоретичният моменти, $k = 1, 2, \dots$

$\bar{x}_n^{(k)} = \frac{1}{n} \sum_{i=1}^n x_i^k \rightarrow$ емпиричният моменти, $k = 1, 2, \dots$

Тогава решението на същата е: $\mu^{(k)}(\theta) = \bar{x}_n^{(k)}$ за $k = 1, \dots, s$,

и е нарица оценка по М.М.Н.

→ (Твойски бр.:

* Задача (независимост):

Каскаде, че $\hat{\theta}$ е независима оцена на θ , ако
 $E(\hat{\theta}|\vec{x}) = \theta$. Когато $\theta = (\theta_1, \dots, \theta_s)$, работният съдържа се
разделя на $\theta_1, \dots, \theta_s$ и $E(\hat{\theta}_j|\vec{x}) = \theta_j$, $1 \leq j \leq s$.

Следствие, ако юбъло не е извършено, юбълът
 $|E(\hat{\theta} - \theta)|$ не е редица симетрична гранична.

* $|E(\hat{\theta} - \theta)| = 0 \rightarrow$ юбълът е независим

* Задача (съвпадение):

Ако $E(\hat{\theta}|\vec{x}) \xrightarrow[n \rightarrow \infty]{P} \theta$, юбълът $\hat{\theta}$ е съвпадение оцена.

• Каскада означава юбълът $\hat{\theta}$ е

$$\theta \in \mathbb{R} \Rightarrow P(|E(\hat{\theta}|\vec{x}) - \theta| > \epsilon) \xrightarrow[n \rightarrow \infty]{P} 0$$

→ и.е. юбълът $\hat{\theta}$ е съвпадение оцена когато $\theta = 0$, и.е. това как юбълът $\hat{\theta}$ е θ ?

* Задача (съвпадение):

Ако $E(\hat{\theta}|\vec{x}) \xrightarrow[n \rightarrow \infty]{a.s.} \theta$, юбълът $\hat{\theta}$ е съвпадение оцена.

* Задача: фундаменталният принцип на МП наричаме съвпадение оцена на \vec{x} , и.е.

$$L(\vec{x}, \theta) = \prod_{i=1}^n \varphi(x_i|\theta)$$

→ понятие от ст. Ген.
са независими и съвпадение
предпоставка

→ Неравенство на Берн-Ессе (поглощено)

$$x_n \sim \text{Ber}(p) \Rightarrow \mathbb{E} |x_n - p|^3 = p(1-p)(p^2 + (1-p)^2) \leq \frac{1}{16}$$

Причина $n \geq 30 \Rightarrow \text{ЦТ} \in \text{Банах}?$

Следствие: $x_n \sim \text{Bin}(n, p)$

$$\text{Тогда. } a < b \lim_{n \rightarrow \infty} P(a < \frac{x_n - np}{\sqrt{np(1-p)}} < b) = \\ = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{y^2}{2}} dy = \Phi(b) - \Phi(a)$$

$$g-60^\circ \quad \sigma = \sqrt{p(1-p)}$$

$$x_n = \sum_{i=1}^n y_i \quad y_i \sim \text{Ber}(p)$$


$$P(a < \frac{\sum_{i=1}^n y_i - np}{\sqrt{np(1-p)}} < b) = P\left(\frac{\sum_{i=1}^n y_i - np}{\sqrt{np(1-p)}} < b\right) - P\left(\frac{\sum_{i=1}^n y_i - np}{\sqrt{np(1-p)}} \leq a\right)$$

$$\xrightarrow[n \rightarrow \infty]{\text{ЦТ}} \Phi(b) - \Phi(a)$$

Изменяя смещение центра неравенства

$$\begin{cases} A \neq 0, & A \\ \neq 0, & \delta A \end{cases}$$

$$\begin{aligned} f(x,y) &\text{ е вен. ф. } (x,y) \\ Af &= \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \end{aligned}$$



* (n: $x_n \sim \text{Bin}(n, p)$). Тогда $\frac{x_n - np}{\sqrt{np(1-p)}} \xrightarrow[n \rightarrow \infty]{d} Z$.

Задача на дупхне

Будуше брачното обитание в градите еде и да са

$$|u|_{B^j} = \varphi(x, y) \approx \frac{1}{10} \sum_{j=1}^{10} |u|_{B_j^j}$$

Изискава координати на изпиранието є резултат (зададено се
нарида задача на дупхне).

* фонт Модел за разбъркване

Touto bu обичано

33.05

задача: Изследвайте на характеристика (свойства) на събкупността от
обектите (изследвани).

дек: Репрезентативната събкупност (номинация) се нарида събкупността
от едини изследвани обекти.

ГС → Билки българи

Характеристики → рост, мащаб, префереенции, размер

Нека предположим, че X (н.б.) описва изследваната характеристика.
Дополнително, X има об-я на разн. $F_{X|x}$

дек: Създават същия вектор $\vec{X} = (x_1, \dots, x_n)$ от незав. и еднакви
разпределени с н.б. с маргинална об-я f_X .
разпределение $F_{X|x}$ се нарида създаване на изображение с
размер n на X .

\vec{X} са точки на X

Ръзбен 38%

2,38 хиляди избиратели

Пример: Digest \hookrightarrow 4000 от. избрани гласове подавали \rightarrow Ръзбен 56%

Нека предположим, че $F_{X|x} = F_{X|x}$, т.е. разпределението на
 X за всички от избирателите е едно и същото

\hookrightarrow Единото е да
е вектор от параметри

⊕ Пример: $X \sim N(\mu, \sigma^2)$

$$\Theta = (\mu, \sigma^2)$$

$$f(x|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\mu \in \mathbb{R}$
 $\sigma^2 \in [0, +\infty)$

⊕ Пример: $X \sim \text{Ber}(p)$, $X \sim \text{Bin}(n, p)$

$$\Theta = p$$

$$\Theta = (n, p)$$

+ Def: функцията $\Theta = \Theta(\vec{x})$ се нарича оценка (која е наричана и надеждна оценка).

+ Задача: односно Θ се избира преди го измерим реалниот заеднички \vec{x}

$$\vec{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$$

$\Theta(\vec{x}) \rightarrow$ шанса оценка

$\Theta(\vec{x}) \rightarrow$ надеждна оценка

A. Метод на максималното правдоподобие (М.П.)

Предполагаме, че \vec{x} е изважка на $X \sim \text{ob.p. } f(x|\theta)$ и надеждна $f(x|\theta)$

+ Def: (обично се нарича така $\vec{x} = (x_1, \dots, x_n)$)

$$f(x_1, \dots, x_n | \theta) = \prod_{j=1}^n f(x_j | \theta) := L(\vec{x}, \theta)$$

се нарича обикновено правдоподобие.


⊕ Пример: $n=1$ $X \sim N(\mu, 1)$ $\Theta = \mu$

$$L(x, \theta) = L(x_1, \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_1-\mu)^2}{2}}$$

$$P(X \in (x_i - \varepsilon; x_i + \varepsilon)) =$$

$$= \int_{x_i - \varepsilon}^{x_i + \varepsilon} \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} dx \approx 2\varepsilon f(x_i, \mu)$$

големина на
един ерарх



$$L(\vec{x}, \theta) = \prod_{j=1}^n f(x_j | \theta)$$

$$\mu \rightarrow \sup_{\mu} f_x(x_1, \mu)$$

$$\hat{\mu}(x_1) = x_1$$

Def: Статистиката $\hat{\theta}(\vec{x})$ се нар. оценка на нещо θ при н.н., ако $L(\vec{x}, \hat{\theta}) = \sup_{\theta \in \Theta} L(\vec{x}, \theta)$, т.е. $\hat{\theta}$ е максимална възможна оценка за θ .

Aко $f_x(x, \theta)$ е гр. фнк. на θ , то $\hat{\theta}$ е резултат.

$$\frac{\partial L}{\partial \theta} = 0 \iff \frac{\partial \ln L}{\partial \theta} = 0 \quad \text{нр. е мон. фнк.} \rightarrow \text{и има с-бо производителство за идентични}$$

4) Пример: $X \sim U(0, \theta)$, $\Theta = [0, +\infty)$

\vec{x} е избагка за X

$$f_x(x) = \begin{cases} \frac{1}{\theta}, & x \in [0, \theta] \\ 0, & x \notin [0, \theta] \end{cases}$$

$$L(\vec{x}, \theta) = \prod_{j=1}^n f_{x_j}(x_j) =$$

$$= \prod_{j=1}^n \frac{1}{\theta} \mathbb{1}_{\{x_j \in [0, \theta]\}}$$

$$= \frac{1}{\theta^n} \mathbb{1}_{\{\max\{x_1, \dots, x_n\} \in [0, \theta]\}}$$

$\frac{1}{\theta^n} \rightarrow$ максимална гр. фнк. на θ

$$\hat{\theta}(\vec{x}) = \max\{x_1, \dots, x_n\}$$

$$\hat{\theta}(\vec{x}) = \max\{x_1, \dots, x_n\} \rightarrow \text{макс.}$$

Б. Моменты и моментные

Он, ЗГУ X с. Ген. $E(X) = \mu$

$$\bar{X}_n \xrightarrow{n \rightarrow \infty} \mu \text{ (сущ.) } P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

$$\bar{X}_n \xrightarrow{P} \mu \text{ (снад)} \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \varepsilon) = 0, \forall \varepsilon > 0$$

* Def: Нека X има обр. $F_X(x, \theta)$, \bar{x} е изброяно за X ,
 $E(X^k) = \mu^{(k)}(\theta) \rightarrow$ моментни моменти,
 $k=1, 2, \dots$

$$\bar{X}_n^{(k)} = \frac{1}{n} \sum_{j=1}^n X_j^k \rightarrow$$
 empirични моменти, $k=1, 2, \dots$

и $\Theta = (\theta_1, \dots, \theta_s)$. Тога, решение за оценяване

$$\mu^{(k)}(\theta) = \bar{X}_n^{(k)} \text{ за } k=1, \dots, s$$

θ се нарича оценка на М.М.

* Пример: $X \sim U(0, \theta)$, \bar{x} е изброяно за X

$$\hat{\theta} = \max(X_1, \dots, X_n)$$

$$E(X) = \frac{\theta}{2} \quad \frac{\theta}{2} = \bar{X}_n$$

$$\bar{X}_n = \frac{1}{n} \sum_{j=1}^n X_j \quad \hat{\theta} = 2\bar{X}_n + \bar{X}_n$$

* Пример: $X \sim N(\mu, \sigma^2)$, \bar{x} е изброяно

$$E(X) = \mu$$

$$E(X^2) = \sigma^2 + \mu^2$$

$$\boxed{\mu = \bar{X}_n} \quad \hat{\mu} = \bar{X}_n \quad \left. \begin{array}{l} \hat{\mu} = \bar{X}_n \\ \sigma^2 + \mu^2 = \bar{X}_n^{(2)} = \frac{1}{n} \sum_{j=1}^n X_j^2 \end{array} \right\} \text{заместваме}$$

$$\sigma^2 = \frac{1}{n} \sum_{j=1}^n X_j^2 - (\bar{X}_n)^2 = \bar{X}_n^{(2)} - (\bar{X}_n)^2 = \sigma^2$$

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2 = \frac{1}{n} \sum_{j=1}^n (x_j^2 - 2x_j \bar{x}_n + (\bar{x}_n)^2) = \\ &= \frac{1}{n} \sum_{j=1}^n x_j^2 - \frac{2}{n} \bar{x}_n \sum_{j=1}^n x_j + \frac{1}{n} \cdot n \cdot (\bar{x}_n)^2 = \\ &= \bar{x}_n^{(2)} - (\bar{x}_n)^2 \end{aligned}$$

* Бойсичка на оценките

*Def: Нека $\Theta(\vec{x})$ е оценка (оценка) за Θ , базирана на съглаждана избира \vec{x} под см. Ген. X .

$\Theta(\vec{x})$ е нормална оценка за Θ , ако

$$\mathbb{E}(\Theta(\vec{x}) - \Theta) = 0$$

$\Theta(\vec{x}) - \Theta \rightarrow$ математическа грешка

*) Пример: $X \sim N(\mu, \sigma^2)$ $\mathbb{E}X = \mu$ $DX = \sigma^2$

$$\hat{\mu} = \bar{x}_n$$

$$\begin{aligned} \mathbb{E}(\hat{\mu} - \mu) &= 0 \Leftrightarrow \mathbb{E}\hat{\mu} = \mathbb{E}\left(\frac{1}{n} \sum_{j=1}^n x_j\right) = \frac{1}{n} \mathbb{E}\sum_{j=1}^n x_j = \\ &= \frac{1}{n} \sum_{j=1}^n \mathbb{E}x_j = \frac{1}{n} \cdot \sum_{j=1}^n \mu = \frac{1}{n} \cdot n \cdot \mu = \mu \end{aligned}$$

избира x_1, x_2, \dots, x_n съвсъд разпределение

$\rightarrow \hat{\mu}$ е нормална оценка

$$\begin{aligned} \mathbb{E}(\hat{\sigma}^2) &= \mathbb{E}\left[\frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2\right] = \mathbb{E}[\bar{x}_n^{(2)} - (\bar{x}_n)^2] = \\ &= \mathbb{E}\left[\left(\frac{1}{n} \sum_{j=1}^n x_j^2\right)\right] - \mathbb{E}\left[\left(\frac{1}{n} \sum_{j=1}^n x_j\right)^2\right] = \\ &= \frac{1}{n} \sum_{j=1}^n \mathbb{E}x_j^2 - \frac{1}{n^2} \mathbb{E}\left[\sum_{j=1}^n x_j^2 + \sum_{i \neq j} \mathbb{E}(x_i x_j)\right] = \\ &= \frac{1}{n} \cdot n (\sigma^2 + \mu^2) - \frac{1}{n^2} \sum_{j=1}^n \mathbb{E}x_j^2 - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E}(x_i x_j) = \end{aligned}$$

$\mathbb{E}x_i x_j = \mu \cdot \mu = \mu^2$

$$\begin{aligned}
 &= \sigma^2 + \mu^2 - \frac{1}{n^2} \cdot n(\sigma^2 + \mu^2) - \frac{1}{n^2} 2 \cdot \left(\frac{n}{2} \right) \cdot \mu^2 \\
 &\quad \text{здесь } \frac{n(n-1)}{2} \text{ значит } \\
 &= \sigma^2 + \mu^2 - \frac{1}{n} (\sigma^2 + \mu^2) - \frac{1}{n} n(n-1) \mu^2 = \\
 &= (\sigma^2 + \mu^2) \left(1 - \frac{1}{n} \right) - \left(1 - \frac{1}{n} \right) \mu^2 = \\
 &= \left(1 - \frac{1}{n} \right) \cdot \sigma^2 = \frac{n-1}{n} \sigma^2 + \sigma^2 \Rightarrow \text{о.е. несущая} \\
 &\frac{n-1}{n} \sigma^2 = s^2 \Rightarrow \# s^2 = \frac{n}{n-1} \quad \# \sigma^2 = \frac{n}{n-1} \cdot \frac{n-1}{n} \sigma^2 = \sigma^2 \\
 &\text{изображение о.е.} \Rightarrow \text{оценка несущая} \\
 &\text{здесь несущая}
 \end{aligned}$$

④ Пример:

$$\begin{aligned}
 x_i \sim U(0, \Theta) \quad \Theta = \max\{x_1, \dots, x_n\} = Y \quad F_Y(y) = \frac{y}{\Theta} \\
 P(Y \leq y) = P(\max\{x_1, \dots, x_n\} \leq y) \\
 F_Y(y) = P(x_1 \leq y, \dots, x_n \leq y) \\
 = P(x_1 \leq y) \dots P(x_n \leq y) \\
 = \left(\frac{y}{\Theta} \right)^n \quad \text{здесь } y \in [0, \Theta] \\
 \# \hat{\Theta} = EY = \int_0^\Theta \frac{y \cdot ny^{n-1}}{\Theta^n} dy = \\
 = \frac{n}{\Theta^n} \cdot \frac{y^{n+1}}{n+1} \Big|_0^\Theta = \frac{n}{\Theta^n} \cdot \frac{\Theta^{n+1}}{n+1} = \frac{n}{n+1} \Theta \neq \Theta \\
 \text{т.е. несущая}
 \end{aligned}$$

$$P(Y \leq y) = \frac{ny^{n-1}}{\Theta^n}$$

$$\text{здесь: } \boxed{\# \hat{\Theta} = ?}$$

* Def: Käsbane, se $\Theta(\vec{x}) \in$ sümogumenta (wahnta süm), aks

$$\Theta(\vec{x}) \xrightarrow[n \rightarrow \infty]{P} 0 \quad (\Theta(\vec{x}) \xrightarrow[n \rightarrow \infty]{\text{n.c.}} 0)$$

Θ e ay no hewdy ta momentane (n.u.)

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{P} \mathbb{E}X \text{ cnas } 3\Gamma Y$$

$\vec{X}_n^{(k)} \xrightarrow[n \rightarrow \infty]{P} \mathbb{E}X^k$, aks $\mathbb{E}|X|^k < \infty$ cbyg (kpach e)

$$Y = X^k$$

Ako $\mathbb{E}X, \mathbb{E}X^2, \dots, \mathbb{E}X^k, \dots$, cq usberiit, wd mba egnozhatito mi onpege? $f_X(x)$?

* Tcibrgume: Heka $X \sim N(\mu, \sigma^2)$ u \vec{X} e usbergra tag x.

Tora ba mn.o. za μ e $\hat{\mu}(\vec{x}) = \bar{X}_n = \frac{1}{n} \sum_{j=1}^n x_j$

Ihesabuvimo qam $\hat{\sigma}^2$ e usberiit vun he 1, a za σ^2 e:

i) $\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2$, korato μ e usberiit

ii) $\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{X}_n)^2$, korato μ e henuzberiit

g-60: $\Theta = (\mu, \sigma^2)$

$$\begin{aligned} L = (\vec{x}, \Theta) &= \prod_{j=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_j - \mu)^2}{2\sigma^2}} = \\ &= \left(\frac{1}{2\pi} \right)^{n/2} \left(\frac{1}{\sigma^2} \right)^{\frac{n}{2}} e^{-\sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2}} \end{aligned}$$

$$\ln L(\vec{x}, \Theta) = \frac{n}{2} \ln \left(\frac{1}{2\pi} \right) - \frac{n}{2} \ln(\sigma^2) - \sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2}$$

$$\frac{\partial \ln L}{\partial \mu} = \frac{\sum_{j=1}^n (x_j - \mu)}{\sigma^2} = 0 \Rightarrow \sum_{j=1}^n x_j - n\mu = 0$$

$$\Rightarrow \hat{\mu} = \frac{1}{n} \sum_{j=1}^n x_j = \bar{X}_n$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{\sum_{j=1}^n (x_j - \mu)^2}{2\sigma^4} = 0 \quad | \circ 2\sigma^4$$

$$-na^2 + \sum_{j=1}^n (x_j - \mu)^2$$

$$\sigma^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2$$

i) $\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2$

ii) $\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2$

Доверительные интервалы

$$\hat{\theta} = \hat{\theta}(\vec{x}), \vec{x} = (x_1, \dots, x_n) \quad (\vec{x} = (x_1, \dots, x_n) \Rightarrow \hat{\theta} = \hat{\theta}(\vec{x}))$$

$\theta \in \mathbb{R}$ и есть выборки $(I_1(\vec{x}), I_2(\vec{x}))$, такие, что

$$P(I_1 \subset I_2) \geq \gamma$$

$$I_1 := I_1(\vec{x})$$

$$I_2 := I_2(\vec{x})$$

тогда он доверен

$$(\gamma = 0,9, 0,55, 0,99)$$

(I_1, I_2) — это пары доверительных интервалов

$$\vec{x}, (I_1(\vec{x}), I_2(\vec{x}))$$

$$\vec{y}, (I_1(\vec{y}), I_2(\vec{y}))$$

Четвертная статистика


Несколько $T(\vec{x}), \theta$ — статистика. Чем: $KasGame$, что T — четвертная статистика, если:

a) T — первая монотонная (\uparrow) по θ

то θ — функц. T , то распределение θ и

$$\delta) P(T \leq x) = F_T(x)$$

не зависит от θ



$$P(q_1 < T < q_2) = F_T(q_2) - F_T(q_1) \geq \gamma$$

$$P(T^{-1}(q_1) < \theta < T^{-1}(q_2))$$

I_1

I_2

$$P(\varrho_1 < T_1 < \varrho_2) = \gamma$$

Егъта задача е да се минимизира $\varrho_2 - \varrho_1$ при $I_2 - I_1$

④ $X \sim N(\mu, \sigma^2)$, когато σ^2 е известно. $\Theta = \mu$.


$\vec{X} = (X_1, \dots, X_n)$, $X_i \sim N(\mu, \sigma^2)$, $1 \leq i \leq n$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \xrightarrow{\text{недостатъко}} \text{значи } \sigma^2 \text{ не е}$$

$$T(\vec{X}, \mu) = \frac{\bar{X}_n - \mu}{\sigma \sqrt{n}} \sim N(0, \frac{\sigma^2}{n}) \quad \left(\sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2) \right) \sim N(0, 1)$$

последните
също съдържат μ
и също съдържат n

$$\gamma = P(\varrho_1 < T < \varrho_2) =$$



$$= P\left(\frac{\varrho_1 - \gamma}{\sigma \sqrt{n}} < T < \frac{\varrho_2 - \gamma}{\sigma \sqrt{n}}\right) =$$

$$= P\left(-\frac{\varrho_1 - \gamma}{\sigma \sqrt{n}} < T < \frac{\varrho_2 - \gamma}{\sigma \sqrt{n}}\right) = P\left(-2 \frac{\varrho_1 - \gamma}{\sigma \sqrt{n}} < \frac{\bar{X}_n - \mu}{\sigma \sqrt{n}} < 2 \frac{\varrho_2 - \gamma}{\sigma \sqrt{n}}\right) =$$

$$= P\left(-2 \frac{\frac{\varrho_1 - \gamma}{\sigma}}{\sqrt{n}} < \bar{X}_n - \mu < 2 \frac{\frac{\varrho_2 - \gamma}{\sigma}}{\sqrt{n}}\right) = P\left(\bar{X}_n - \frac{\sigma}{\sqrt{n}} \cdot 2 \frac{\varrho_1 - \gamma}{\sigma} < \mu < \bar{X}_n + 2 \frac{\varrho_2 - \gamma}{\sigma} \cdot \frac{\sigma}{\sqrt{n}}\right)$$

④ $X \sim N(\mu, \sigma^2)$ $\Omega = \mu$ то имеем информативность σ^2

$S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}_n)^2$ есть несмешанная оценка для σ^2 .

$$S^2 \perp \bar{X}_n \text{ и } \frac{(n-1) S^2}{\sigma^2} = \sum_{j=1}^n \frac{(X_j - \bar{X}_n)^2}{\sigma^2} \sim \chi^2_{n-1}$$

x-нечетные

$$T(\bar{X}, \mu) = \frac{\bar{X}_n - \mu}{\frac{S}{\sqrt{n}}} = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}} \cdot \frac{1}{\sqrt{n-1}}} \sim \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

ако не земам да σ ? \smile випада ли?

и как же примеры?? \rightarrow

+ распределение

$$\gamma = P\left(-2 \frac{1+\gamma}{2} < \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} < 2 \frac{1+\gamma}{2}\right) =$$

$$= P\left(\bar{X}_n - \frac{\sigma}{\sqrt{n}} 2 \frac{1+\gamma}{2} < \mu < \bar{X}_n + \frac{\sigma}{\sqrt{n}} 2 \frac{1+\gamma}{2}\right)$$


$t(n-1)$

$$I_1 = \bar{X}_n - \frac{\sigma}{\sqrt{n}} 2 \frac{1+\gamma}{2}$$

$$I_2 = \bar{X}_n + \frac{\sigma}{\sqrt{n}} 2 \frac{1+\gamma}{2}$$

Приближительно $t(n)$ с 2 кора?

шанс дарит то же
на практике



короче $n-1 \geq 30$

и не работим с квадратичной на t, а с квадратичной

-says same sample + cbc t

$$T = \frac{Z}{\sqrt{\frac{Y}{n-1}}} \rightarrow \text{нормальная распределение}$$

$$Y_i \sim \chi^2(n-1)$$

$$\sum_{j=1}^{n-1} Y_j \sim \chi^2(n)$$

$\int n \rightarrow \infty$ \rightarrow $\chi^2(n)$ распределение не имеет

достаточная статистика для σ^2 : $X \sim N(\mu, \sigma^2)$

a) $\mu \rightarrow$ центральная, \bar{X}

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (\bar{X}_j - \mu)^2 = \frac{1}{n} \sum_{j=1}^n \left(\frac{X_j - \mu}{\sigma} \right)^2$$


$\chi^2(n) \rightarrow$ $\chi^2(n)$ распределение с n степенями свободы

$$T = n \frac{\hat{\sigma}^2}{\sigma^2} = \sum_{j=1}^n \frac{(\bar{X}_j - \mu)^2}{\sigma^2} = \chi^2(n)$$

$$\gamma = P \left| 2 \frac{1-\alpha}{2} < \frac{n \hat{\sigma}^2}{\sigma^2} < 2 \frac{1+\alpha}{2} \right| =$$

$$P \left| \frac{n \hat{\sigma}^2}{2 \frac{1-\alpha}{2}} < \frac{n \hat{\sigma}^2}{2 \frac{1+\alpha}{2}} \right| =$$

$$I_1 = n \cdot \frac{1}{n} \sum_{j=1}^n (\bar{X}_j - \mu)^2 = ?$$



$$I_2 = \frac{\sum_{j=1}^n (\bar{X}_j - \mu)^2}{2 \frac{1-\alpha}{2}}$$

ако μ не се стое

$$I_1 = \frac{\sum_{j=1}^n |x_j - \bar{x}_n|^2}{2 \cdot \frac{n+1}{2}}$$

$$I_2 = \frac{\sum_{j=1}^n |x_j - \mu|^2}{2 \cdot \frac{n-1}{2}}$$

Пробека на хипотези

Пример: има сърдечни ефекти, га ратен

Матем. постановка: $X, F(x, \theta)$; \vec{x} - изброя. $\vec{x} = (x_1, \dots, x_n)$

$H_0: \theta = \theta_0 \rightarrow$ нулева / базова хипотеза нрави средната

$H_1: \theta = \theta_1 \rightarrow$ альтернативна хипотеза

чен: Търсим $W \subseteq \mathbb{R}^n$ (кръгълта област) на \vec{x} , за което $\vec{x} \in W$

да хвърляме H_0 , а ако $\vec{x} \in W^c$ приемаме H_0 .

помагаме \vec{x} и ако $\vec{x} \in W$ да хвърляме H_0
 $I \in W^c$ приемаме H_0

$\alpha = P(\vec{x} \in w | H_0) = \alpha_w \rightarrow$ грешка от неправилнога

$\beta = P(\vec{x} \notin w^c | H_1) = \beta_w \rightarrow$ грешка от близорукога

Избирају се $\alpha \in \{0,1; 0,05; 0,01\} \Rightarrow$ избирају се $w; \alpha_w = \alpha$

$\beta_w = P(\vec{x} \in w^c | H_1) \rightarrow$ допустимо је гаранција да
е опасна, а сигуларни не је
да је ешталкова грешка драматична,
но обично је!

* Задатак: Као ванвеј, да се $w^* \in \mathbb{R}^n$ је оптимална критичка односно локација
за грешку око неправилнога α , ако

$\beta_w^* = \inf \beta_w \rightarrow$ иначе β_w^* , који је оптимална (минимална)

$$\alpha_w = \alpha$$

$$H_w \subseteq \mathbb{R}^n$$

Насупрот

* Нема таја нулестот:

$x \sim F_x(x, \theta)$ и лобитар $f_x(x, \theta)$

$$H_0: \theta = \theta_0$$

$$H_1: \theta = \theta_1$$

$$L(\vec{x}, \theta) = \prod_{j=1}^n f(x_j, \theta)$$

$$L_1(\vec{x}) = L(\vec{x}, \theta_1)$$

$$L_0(\vec{x}) = L(\vec{x}, \theta_0)$$

$$\vec{x} \in L_1(\vec{x})$$

• La nema:

Hera $\vec{x} \sim f(x|\theta)$, $\vec{x} = (x_1, \dots, x_n)$ u raznopravame

$$H_0: \theta = \theta_0$$

$H_1: \theta = \theta_1$. Torača ars za segajeta ravnata oti "BpE"

pog α e leprivo, se $\alpha = P(\vec{x} \in N | H_0) = \alpha$ u

$$\begin{aligned} W^* &\subseteq \{ \vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq k L_0(\vec{x}) \} \\ \text{ce bñara} \end{aligned}$$

$(W^*)^c \subseteq \{ \vec{x} \in \mathbb{R}^n : L_0(\vec{x}) \leq k L_1(\vec{x}) \}$, kogato $k > 0$ e
konstanta, kogato niste
ga sañuci oti?

Torača W^* e o.k.o

⊕ $\alpha = 0,05$

$$W_k = \{ \vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq k L_0(\vec{x}) \}$$

Ako namenjujte k^* :
$$\alpha_{W_k^*} = \alpha = 0,05$$

$$W^* = W_{k^*} = \{ \vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq k^* L_0(\vec{x}) \}$$

$$P(L_1(\vec{x}) \geq k^* L_0(\vec{x}) | H_0) = 0,05 \quad \text{nema} \Rightarrow W^* \text{ e o.k.o}$$

$$\text{g-60: } \omega = P(\vec{x} \in \omega^*)|_{H_0} = \int_{\omega^*} L_0(\vec{x}) d\vec{x} = \omega^* = P(\vec{x} \in \omega)|_{H_0} =$$

$$\int_{\omega} L_0(\vec{x}) d\vec{x}$$

$$\int_{\omega} L_0(\vec{x}) d\vec{x} = \int_{\omega^* \cap \omega} L_0(\vec{x}) d\vec{x} + \int_{\omega^* \setminus \omega} L_0(\vec{x}) d\vec{x} =$$

$$= \int_{\omega} L_0(\vec{x}) d\vec{x} = \int_{\omega \cap \omega^*} L_0(\vec{x}) d\vec{x} + \int_{\omega \setminus \omega^*} L_0(\vec{x}) d\vec{x} =$$

$$= \int_{\omega^* \cap \omega} L_0(\vec{x}) d\vec{x} = \int_{\omega \cap \omega^*} L_0(\vec{x}) d\vec{x} \quad \beta \omega \geq \beta \omega^*$$

$$p\omega = P(\vec{x} \in \omega^* | H_1) = \underbrace{\int_{\omega^*} L_1(\vec{x}) d\vec{x}}_{\text{VI?}} - \beta \omega^* + \beta \omega^* \geq \beta \omega^*$$

$$\underbrace{\int_{\omega^*} L_1(\vec{x}) d\vec{x}}_{\text{VI?}} - \beta \omega^* + \beta \omega^* \geq \beta \omega^*$$

$$\int_{\omega^*} L_1(\vec{x}) d\vec{x} = \int_{(\omega^*)^c} L_1(\vec{x}) d\vec{x} = \int_{\omega^* \cap \omega^c} L_1(\vec{x}) d\vec{x} + \int_{\omega^* \setminus (\omega^*)^c} L_1(\vec{x}) d\vec{x} - \int_{\omega^* \setminus (\omega^*)^c} L_1(\vec{x}) d\vec{x}$$

$$- \int_{(\omega^*)^c \cap \omega} L_1(\vec{x}) d\vec{x} = \int_{\omega^* \cap \omega^c} L_1(\vec{x}) d\vec{x} - \int_{(\omega^*)^c \cap \omega} L_1(\vec{x}) d\vec{x} \geq \int_{\omega^* \cap \omega^c} k L_0(\vec{x}) d\vec{x} -$$

$$\int_{\omega^* \cap \omega^c} k L_0(\vec{x}) d\vec{x} = 0 \quad \text{(A)}$$

- g $(\omega^*)^c \cap \omega$

④ $x \sim N(\mu, \sigma^2)$, σ^2 e usbekātā

$\vec{x} = (x_1, \dots, x_n)$ u spēkām oī
noplēcīgām α

$$H_0: \mu = \mu_0$$

$$(\mu_0 < \mu_1)$$

$$H_1: \mu = \mu_1$$

$$L_0(\vec{x}) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \cdot \prod_{j=1}^n e^{-\frac{(x_j - \mu_0)^2}{2\sigma^2}}$$

$$L_1(\vec{x}) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \cdot \prod_{j=1}^n e^{-\frac{(x_j - \mu_1)^2}{2\sigma^2}}$$

$$W_k = \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq k L_0(\vec{x})\} = \{\vec{x} \in \mathbb{R}^n : e^{-\sum_{j=1}^n \frac{(x_j - \mu_1)^2}{2\sigma^2}} \geq k e^{-\sum_{j=1}^n \frac{(x_j - \mu_0)^2}{2\sigma^2}}\} =$$

$$\alpha = P(\vec{x} \in W_k | H_0) = P\left(\frac{\sum_{j=1}^n x_j}{n} \geq \bar{x}_0 | H_0\right) =$$

~~$$\{\vec{x} \in \mathbb{R}^n : \sum_{j=1}^n \frac{(x_j - \mu_1)^2}{2\sigma^2} \leq \sum_{j=1}^n \frac{(x_j - \mu_0)^2}{2\sigma^2}\}$$~~

$$= \{\vec{x} \in \mathbb{R}^n : -\sum_{j=1}^n (x_j - \mu_1)^2 \geq 2\sigma^2 L_1 - \varepsilon\}$$

$$x_0 \sim N(\mu_0, \sigma^2)$$

$$\Rightarrow P\left(\frac{\sum_{j=1}^n x_j - n\mu_0}{\sigma\sqrt{n}} \geq \frac{k_2 - n\mu_0}{\sigma} \mid H_0\right) = P(Z \geq \frac{k_2 - n\mu_0}{\sigma}) = \alpha$$

$$= 1 - \Phi\left(\frac{k_2 - n\mu_0}{\sigma}\right) = \alpha \Leftrightarrow \Phi\left(\frac{k_2 - n\mu_0}{\sigma}\right) = 1 - \alpha$$


Линейна перспекция

Ганшот - искан га направи изследвайте дали има разлика между ръцете на бояда и син

$$y_{\text{син}} = x_{\text{средно}} + \beta(x_{\text{бояда}} - x_{\text{средно}}), \quad \beta \approx 0,6$$

$$x_{\text{бояда}} - x_{\text{средно}} = 10 \text{ см} \Rightarrow y_{\text{син}} = x_{\text{средно}} + 6 \text{ см}$$

в перспектива се що ти бояда обрашто към средното



$$y_k = b_0 + b_1 x_k + \epsilon_k$$

$$\hat{y} = b_0 + b_1 x$$

$$f(b_0, b_1) = \sum_{k=1}^n |y_k - \hat{y}_k|^2 = \sum_{k=1}^n |y_k - b_0 - b_1 x_k|^2$$


в минимизираме по бояда някои $(b_0, b_1 \dots)$

$$\rightarrow \text{чен } \hat{b}_0, \hat{b}_1 \text{ при } \sum_{k=1}^n |y_k - \hat{y}_k|^2 = \inf_{\substack{b_0, b_1 \\ \hat{b}_0 - b_1 x_k}} \sum_{k=1}^n |y_k - b_0 - b_1 x_k|^2$$

в какво се базира това обясня?

$$0 = \frac{\partial f}{\partial b_0} = -2 \sum_{k=1}^n (y_k - b_0 - b_1 x_k)$$

$$0 = \frac{\partial f}{\partial b_1} = -2 \sum_{k=1}^n x_k (y_k - b_0 - b_1 x_k)$$



в парабола, която има глобален минимум

$$\textcircled{1} = \bar{y} - b_0 - b_1 \bar{x}$$

$$\rightarrow \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$= \sum_{k=1}^n (x_k y_k - b_0 \bar{x} - b_1 \sum_{k=1}^n x_k^2)$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$b_1 = \frac{\sum_{k=1}^n (x_k - \bar{x}) y_k}{\sum_{k=1}^n (x_k - \bar{x})^2}$$

$$\bar{y} = b_0 + b_1 \bar{x} \Rightarrow b_0 = \bar{y} - b_1 \bar{x}$$

$$b_0 = \bar{y} - b_1 \bar{x} = \sum_{k=1}^n y_k \left(\frac{1}{n} - \frac{\bar{x}}{\sum_{k=1}^n (x_k - \bar{x})^2} \right)$$


$$\sum_{k=1}^n x_k y_k - b_1 \sum_{k=1}^n x_k^2 = n b_0 \bar{x} = n (\bar{y} - b_1 \bar{x}) \bar{x} \Rightarrow$$

$$\sum_{k=1}^n x_k y_k - n \bar{y} \bar{x} = b_1 \left(\sum_{k=1}^n x_k^2 - n \bar{x}^2 \right)$$

$$b_1 = \frac{\sum_{k=1}^n x_k y_k - n \bar{y} \bar{x}}{\sum_{k=1}^n x_k^2 - n \bar{x}^2} = \frac{\sum_{k=1}^n (x_k - \bar{x}) y_k}{\sum_{k=1}^n (x_k - \bar{x})^2}$$

$$\sum_{k=1}^n x_k y_k - \bar{x} \sum_{k=1}^n y_k = \sum_{k=1}^n (x_k - \bar{x}) y_k$$

$$b_0 = \bar{y} - b_1 \bar{x} = \frac{1}{n} \sum_{k=1}^n y_k - \sum_{k=1}^n \frac{(x_k - \bar{x}) / \bar{x}}{\sum_{k=1}^n (x_k - \bar{x})^2} y_k =$$



$$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k \rightarrow \text{грешка (авокадо и т.д.)} + \text{авокадо}^{2+0}, \text{ где } \varepsilon_k$$

негатив OP Igosa

$1 \leq k \leq n$

авокадо / результат

авокадо \Rightarrow грешка со нез. б
обратности

* Допущения:

1) $(\varepsilon_1, \dots, \varepsilon_n)$ не зависимы в совокупности

2) $E\varepsilon_k = 0, \quad \forall 1 \leq k \leq n \quad \Rightarrow \hat{Y}_k = \beta_0 + \beta_1 X_k$

средний
авокадо

\Rightarrow в. с. средн. ожидание

3) $D\varepsilon_k = \sigma^2, \quad 1 \leq k \leq n, \quad$ хомоскедастичность

4) $\varepsilon_k \sim N(0, \sigma^2), \quad 1 \leq k \leq n$

$\Rightarrow D Y_k = D\varepsilon_k = \sigma^2$

$$\hat{\beta}_1 = \sum_{k=1}^n \frac{(X_k - \bar{X}) Y_k}{\sum_{k=1}^n (X_k - \bar{X})^2}$$

$$\hat{Y}_k = \hat{\beta}_0 + \hat{\beta}_1 X_k \quad ; \quad Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$$

$$\hat{\beta}_0 = \sum_{k=1}^n Y_k \left(\frac{1}{n} - \frac{\sum (X_k - \bar{X})}{\sum (X_k - \bar{X})^2} \right)$$

оценка

* Неизвестные:

$$\hat{\beta}_1 = E \left[\sum_{k=1}^n \frac{(X_k - \bar{X})}{\sum_{k=1}^n (X_k - \bar{X})^2} Y_k \right] = \sum_{k=1}^n \frac{(X_k - \bar{X})}{\sum_{k=1}^n (X_k - \bar{X})^2} \cdot (\beta_0 + \beta_1 X_k) =$$

β_1

$$= \beta_0 \frac{\sum_{k=1}^n (X_k - \bar{X})}{\sum_{k=1}^n (X_k - \bar{X})^2} + \beta_1 \sum_{k=1}^n \frac{(X_k - \bar{X}) X_k - \bar{X}}{\sum_{k=1}^n (X_k - \bar{X})^2} = \beta_2$$

$$+ \sum \bar{X}(X_k - \bar{X}) = 0$$

учетного на
учетном

$$\rightarrow \hat{\sigma}^2 = \frac{1}{n-2} \sum_{k=1}^n |y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k|^2 = \frac{\sigma^2 \sum_{k=1}^n \frac{(y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k)^2}{\sigma^2}}{n-2}$$

$$\sum_{k=1}^n \frac{|y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k|^2}{\sigma^2} = \sum_{k=1}^n v_k, \quad v_k \sim \chi^2(1)$$

$$= \frac{\sigma^2 \sum_{k=1}^n v_k}{n-2} \xrightarrow[n \rightarrow \infty]{3r^4} \hat{\sigma}^2$$

Теорема: якесі z_1, \dots, z_n са шешілдірілген нормалдық
распределенинде және независимда болса оның квадраттары.

Төртінба $\chi^2 = \sum_{j=1}^n |z_j|^2 \sim \chi^2(n)$

Мәндерелеген:

$$h_j = \text{гешермитишиңкүн} + z_j$$

$$(h_j - \text{гешермитишиңкүн})^2 = z_j^2$$

Ләкин міндеттес таңбасынан оның квадраттары χ^2 болады?

→ Точкови оценки

последни запис

Постановка: X описва некоето свойство на некотора генерална съвкупност, X , $f_{X|x} = P(X|Cx)$, $f_{x|x}$

Идея: $\vec{x} = (x_1, \dots, x_n)$, $(x_j)_{j=1}^n$ са н.е.п. сн. Ген.

$x_i \stackrel{d}{=} X$, на базата на \vec{x} искаме да определим / приближим f_X , f_x

→ $\hat{\theta}$ е функция на наблюденията

където θ е иската оцена за θ

→ ще трябва да изберем така, что да го максимира вероятността

→ функция на максималността на боднодобие, търсимо във видимото лявото да е \vec{x} , т.е.


$$L(\vec{x}; \theta) = \prod_{j=1}^n f_{x|x_j; \theta}$$

→ МПО

• $x \sim N(\mu, 1)$; $\vec{x} = x_1$; $x_1 = x_1$

$$L(\vec{x}; \mu) = f_{x|x_1; \mu}$$

$$L(x_1; \mu) = f_{x|x_1; \mu} \xrightarrow{\text{избирам}} \hat{\mu} = x_1$$



* Всичко лявото има своята максимум в x_1

→ ако изберем μ да е всичко N , вероятността да се настие x_1 е много малка

→ ако вземем да е 6 0, малко по-добре е, но все е малка

→ ако вземем $\mu = x_1$, вероятността да се настие шокът се осъществява и много по-голяма

• Взимам юзы боязор то θ , който юи максимира фунцията на максимално правдоловодие

* Зад: Нека x юе от. вен. с лъжитост $f_x(x, \theta)$,

нека \vec{x} юа независим наблюдение за x ,

Тогава юа МЛО за θ разбираше $\hat{\theta}$:

$$L(\vec{x}, \hat{\theta}) = \sup_{\theta \in \Theta} L(\vec{x}, \theta)$$

→ ако изберем юзы параметър / набор юи параметри /, който максимира юа вероятността вероятността да θ , тогава функцията на правдоловодие / или юи дава максимална вероятност да видим такава реализация)

→ Ако f_x юе диферентуруема по θ , юи $\frac{dL}{d\theta} = 0$, за да намерим екстремума $\hat{\theta}$

→ Понятие L юе производител

$$L(\vec{x}, \theta) = \prod_{j=1}^n f_x(x_j, \theta),$$

зато юе производител на сума и понятие логаритъм юи юе производител функция, еднаквото


да решаваше на $\frac{dL}{d\theta} = 0$ юе

$$\frac{d \ln L}{d\theta} = 0$$

* Когато вземем логаритъм юи производител юа, забележи сума, което юе дава логаритъмът за производителите на производители, когато също сума юи логаритъмът, юи колко юе производител на функцията


$$x \sim U(0, \theta), \quad \theta > 0 \quad f(x) = \frac{1}{\theta} \cdot 1_{[0, \theta]}(x)$$

$$L(\vec{x}, \theta) = \prod_{j=1}^n \frac{1}{\theta} \cdot 1_{[0, \theta]}(x_j) = \frac{1}{\theta^n} \cdot 1_{[0, \theta]}(x^*) = \begin{cases} \frac{1}{\theta^n}, & x^* \leq \theta \\ 0, & x^* > \theta \end{cases}$$




Жасы θ -ға те е жибергендегүү, алар с индикаторъ, киргиз албайтады
бүткөнчөн 0, θ жана 0 избөттүүлүштөрдөн

\Rightarrow Гарыштагында е



$\frac{1}{\theta^n}$ е на максимуму нано θ



$$L(\vec{x}, \theta) = \sup_{\theta > 0} L(\vec{x}, \theta)$$

$$\hat{\theta} = \max_{j \leq n} |x_j|, \quad \hat{\theta} = \hat{\theta}(\vec{x})$$

$\Rightarrow \hat{\theta}$ е максимума то башта надбайтоген

* Төмөрдөтне за МНО за μ жана σ^2

$$g \text{ боз: } L(\vec{x}, \theta) = \left(\frac{1}{2\pi} \right)^n \sigma^n e^{-\sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2}}$$

$$\ln L(\vec{x}, \theta) = n \ln \frac{1}{2\pi} - \frac{n}{2} \ln \sigma^2 - \sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2}$$

$$\begin{aligned} \frac{\partial \ln L}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{j=1}^n (x_j - \mu) = 0 && \text{за га може га съвртим } \frac{\partial \ln L}{\partial \sigma^2} \\ \frac{\partial \ln L}{\partial \sigma^2} &= \frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{j=1}^n (x_j - \mu)^2 = 0 \end{aligned}$$

$$\Rightarrow \begin{aligned} \hat{\mu} &= \frac{1}{n} \sum_{j=1}^n x_j = \bar{x}_n^{(1)} \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2 \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2 \end{aligned}$$

→ Меног та и то нещо

$$\mathbb{E}X = \mu^{(1)}(\theta) ; \quad \theta = (\mu^{(1)})^{-1}(\mathbb{E}X)$$

$$\bar{x}_n^{(1)} = \frac{\sum_{j=1}^n x_j}{n} \xrightarrow[n \rightarrow \infty]{\text{n.c.}} \mathbb{E}X \quad (\text{у3г4})$$

$$\mu^{(1)}(\hat{\theta}) = \bar{x}_n^{(1)}, \quad \hat{\theta} = (\mu^{(1)})^{-1}(\bar{x}_n^{(1)})$$

$$\theta = (\mu^{(1)})^{-1}(\mathbb{E}X)$$

automação
e robótica

$$\underline{\underline{D}} = \frac{\underline{\underline{X}}}{\underline{\underline{A}} \underline{\underline{X}}} = \underline{\underline{A}}^{-1} \underline{\underline{X}} \underline{\underline{A}} + \underline{\underline{B}} = \underline{\underline{A}}^{-1} (\underline{\underline{A}}^{-1} \underline{\underline{X}} \underline{\underline{A}} + \underline{\underline{B}}) = \underline{\underline{A}}^{-1} \underline{\underline{B}}$$

Ato sobre $\underline{\underline{W}}$, $\underline{\underline{D}} \sim N(\underline{\underline{0}}, \underline{\underline{I}})$

$$\underline{\underline{W}} = \frac{\underline{\underline{Y}}}{\underline{\underline{H}} \underline{\underline{X}}} = \underline{\underline{A}}^{-1} \underline{\underline{X}} \underline{\underline{A}} + \underline{\underline{B}} = \underline{\underline{A}}^{-1} (\underline{\underline{X}} \underline{\underline{A}} + \underline{\underline{B}}) = \underline{\underline{A}}^{-1} \underline{\underline{Y}}$$

$\underline{\underline{X}} \sim N(\underline{\underline{0}}, \underline{\underline{I}})$

o parâmetro de propagação da soma é

de forma a não ultrapassar

as restrições impostas pelo problema

matemática

* Cálculo

(a) novo

mais seguro e eficiente para obter o resultado

$$\underline{\underline{W}}_{\text{NO}} = \underline{\underline{W}}_{\text{NO}}$$

$$\underline{\underline{D}} = \underline{\underline{A}}^{-1} (\underline{\underline{Y}} - \underline{\underline{A}} \underline{\underline{A}}^{-1} \underline{\underline{Y}}) = \underline{\underline{A}}^{-1} (\underline{\underline{Y}} - \underline{\underline{A}} \underline{\underline{A}}^{-1} \underline{\underline{A}} \underline{\underline{Y}}) = \underline{\underline{A}}^{-1} (\underline{\underline{Y}} - \underline{\underline{Y}}) = \underline{\underline{0}}$$

$$\underline{\underline{A}}^{-1} \underline{\underline{A}} = \underline{\underline{I}}$$

$$\underline{\underline{W}}_{\text{NO}} = \underline{\underline{A}}^{-1} \underline{\underline{Y}} + \underline{\underline{B}} = \underline{\underline{A}}^{-1} \underline{\underline{Y}} + \underline{\underline{0}} = \underline{\underline{A}}^{-1} \underline{\underline{Y}}$$

$\underline{\underline{D}} = \underline{\underline{X}}$

diminuir
erro

$$\underline{\underline{W}}_{\text{NO}} \leftarrow \underline{\underline{A}}^{-1} \underline{\underline{Y}} = \underline{\underline{0}} \quad \Leftrightarrow \quad \underline{\underline{A}}^{-1} = \underline{\underline{Y}} \underline{\underline{A}}$$

$$\underline{\underline{A}}^{-1} = \underline{\underline{Y}} \underline{\underline{A}} \quad \Leftrightarrow \quad \underline{\underline{A}}^{-1} = \underline{\underline{A}}^{-1} \underline{\underline{A}} \underline{\underline{Y}} \underline{\underline{A}} = \underline{\underline{Y}}$$

o resultado é o

!n

$$\underline{\underline{X}} = \max_{\theta} H(\theta) \quad \underline{\underline{X}} \sim N(0, \underline{\underline{I}})$$

ако тк 3таем M , то $\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n^{(n)})^2$

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \sum_{j=1}^n (\|x_j - \bar{x}_n^{(n)}\|)^2 = \frac{1}{n} \sum_{j=1}^n (\|x_j^2 - 2x_j \bar{x}_n^{(n)} + (\bar{x}_n^{(n)})^2\|) = \\ &= \frac{1}{n} \sum_{j=1}^n \|x_j^2 - \frac{2}{n}\| \end{aligned}$$

••••• *Норма сумбн*

$$\Rightarrow E \hat{\sigma}^2 = \left(\frac{n-1}{n} \right) \sigma^2 \neq \sigma^2 \rightarrow \text{н.е. ожидано е неизменен}$$

Люди га е неизмененна сумма $\frac{1}{n-1}$, при ронено "n"
Норма сумбн а и нона да ожидава

= ако иначина то неизменен

а) равнодиметрични до нормог ожидва

$$\textcircled{1} \quad \theta \in R \quad P(|\hat{\theta}(x) - \theta| \leq \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

коинда синодиметрични

$$\textcircled{2} \quad X \sim N(\mu, \sigma^2) \quad \hat{\mu} = \bar{x}_n^{(n)} \xrightarrow{n \rightarrow \infty} \mu \quad (Y354)$$

П $\hat{\mu}$ ожидано неизменна + в контексте синодиметрични
 с убийствите на избрани, нашеин спектро ще съсънде μ

$$\textcircled{3} \quad X \sim U(0, \theta) \quad \hat{\theta}_1 = \max_{j \leq n} (x_j) ; \quad \hat{\theta}_2 = 2 \bar{x}_n^{(n)}$$

$$\hat{\theta}_2 = 2 \bar{x}_n^{(n)} = \frac{2}{n} \sum_{j=1}^n x_j = \frac{2}{n} \cdot \underbrace{\frac{n}{2}}_{\text{н.е.}} \theta = \theta$$

$$\hat{\theta}_2 = 2 \bar{x}_n^{(n)} \xrightarrow{n \rightarrow \infty} 2 \cdot \frac{\theta}{2} = \theta \Rightarrow \text{(иначо синодиметрични)}$$

$$\rightarrow F_{X^*}(x) = P(X^* < x) = P\left(\bigcap_{j=1}^n \{X_j < x\}\right) = \prod_{j=1}^n P(X_j < x) \quad (\text{независим})$$

за всички случаи да е по-малък,
 когато всички случаи са по-мали
 от x и всички са независими,
 това е произведение

единствено

$$(\Rightarrow) P(X_j < x)^n = \left(\frac{x}{\theta}\right)^n, \quad x \in (0, \theta)$$

$$f_X(x) = F_X'(x) = n \frac{x^{n-1}}{\theta^n}, \quad x \in (0, \theta)$$

$$\theta X^* = \frac{n}{\theta^n} \int_0^x x^n x^{n-1} dx = \frac{n}{\theta^n (n+1)} \theta^{n+1} = \frac{n}{n+1} \theta$$

+
 изисканата
 огледка

$\rightarrow \frac{n+1}{n} \hat{\theta}_n$ е изисканата огледка

$$\text{+ } X \sim N(\mu, 1) : \vec{X} = x_1$$

↳ Unane сн. величина X , която следва нормално разпределение с неизвестна средна аритметична μ и известна дисперсия $\sigma^2 = 1$. Унана еднонадеждното $x_1 = x_1$ и унана га напълни оценка на μ до M, M, \bar{x} .

1. Определяне функцията на приблизеността

$$f(x_1, \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_1 - \mu)^2}{2}}$$

↳ За едно надеждното $x_1 = x_1$

$$L(x_1, \mu) = f(x_1, \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_1 - \mu)^2}{2}}$$

2. Напирайте на логаритмичния приближеността

$$\ln L(x_1, \mu) = \ln \left(\frac{1}{\sqrt{2\pi}} \right) - \frac{(x_1 - \mu)^2}{2}$$

↳ $\ln \left(\frac{1}{\sqrt{2\pi}} \right)$ не зависи от $\mu \Rightarrow$ може да се изхвърли

$$\ln L(x_1, \mu) = -\frac{(x_1 - \mu)^2}{2}$$

3. Максимизирайте тази лог-приближеността:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{2} \left(-\frac{2(x_1 - \mu)}{2} \right) = x_1 - \mu$$

4. Приравняване по изброявана към

$$x_1 - \mu = 0 \Rightarrow \mu = x_1 \Rightarrow \hat{\mu} = \underline{x_1}$$

↳ Това е логично, защото при едно надеждното изброяване за средната аритметична да попадне в един и също надеждното.

$$\frac{\partial}{\partial \mu} \left(-\frac{(x_1 - \mu)^2}{2} \right) = \cancel{-\frac{1}{2} \cdot 2(x_1 - \mu)} = \cancel{x_1 - \mu}$$

$$\cancel{\frac{\partial}{\partial \mu} \left(-\frac{(x_1 - \mu)^2}{2} \right)}$$

$$\Rightarrow \frac{\partial}{\partial \mu} \left(-\frac{1+x_1^2 - 2x_1\mu + \mu^2}{2} \right) = -\frac{1}{2} \cdot (0 + 2x_1 + 2\mu) + 1 = 0$$

może być 0

może być 2x₁

więc kawałek jest

$$\Rightarrow \frac{\partial}{\partial \mu} \left(-\frac{1+x_1^2 - 2x_1\mu + \mu^2}{2} \right) \stackrel{\mu=1}{=} -\frac{1}{2} \cdot (-2x_1 + 2\mu) = -\frac{1}{2} (1-x_1 + \mu) = (1-x_1)$$

Które powietrze

$$L(\vec{x}, \mu) = f(x_1, \mu)$$

$$L(x_1, \mu) = f(x_1, \mu) \Rightarrow \stackrel{\text{+ kątowy}}{\mu = 1}$$

$$\frac{1-x_1}{2} = (1, \mu)$$

$$N - M = \left(\frac{1-x_1}{2} \right) \cdot \left| \frac{ab}{M} \right| = \frac{ab}{M}$$

$$x = \mu \quad x = 0 = 1 - x_1$$

$X \sim U(0, \Theta)$, $\Theta > 0$, $\Theta = [0, +\infty)$

$$\vec{X} = (x_1, x_2, \dots, x_n)$$

$$f(x|x) = \begin{cases} \frac{1}{\Theta^n}, & \text{если } 0 \leq x_i \leq \Theta \\ 0, & \text{иначе} \end{cases}$$

↳чен: да напечим M.L.O за Θ

→ фундаментална на правило нодобие

$$f_{\vec{x}}(x, \Theta) = \begin{cases} \frac{1}{\Theta^n}, & \text{если } 0 \leq x_i \leq \Theta \\ 0, & \text{иначе} \end{cases}$$

$$\Rightarrow L(\vec{x}, \Theta) = \prod_{j=1}^n f_{\vec{x}}(x_j, \Theta) = \prod_{j=1}^n \frac{1}{\Theta^n} \cdot \mathbf{1}_{\{x_j \in [0, \Theta]\}} = \\ = \frac{1}{\Theta^n} \cdot \mathbf{1}_{\{\max(x_1, \dots, x_n) \in [0, \Theta]\}}$$

↳ ини

$$L(\vec{x}, \Theta) = \prod_{j=1}^n f_{\vec{x}}(x_j, \Theta) = \begin{cases} \frac{1}{\Theta^n}, & \text{если } 0 \leq x_i \leq \Theta \\ 0, & \text{иначе} \end{cases}$$

⇒ фундаментална на правило нодобие е нечленеба рано ако $\Theta \geq \max(x_1, \dots, x_n)$

$$\Rightarrow L(\vec{x}, \Theta) = \frac{1}{\Theta^n}, \text{ за } \Theta \geq x_{(n)} \text{ и } 0 \text{ иначе}$$

→ изгледа да максимизираме по Θ , но поне сме $\frac{1}{\Theta^n}$ е на максимум по Θ , и тъй като Θ е граница когато $\Theta \rightarrow \infty$ то $\Theta = x_{(n)}$ е единствената

→ $\hat{\Theta} = x_{(n)}$ → пред M.L.O за Θ е макс-надеждноста

когато си си надеждноста

$$\underline{\hat{\Theta} = \max(x_1, x_2, \dots, x_n) = x_{(n)}}$$

M = M(O)

+) $X \sim U(0, \Theta)$, $\vec{x} = (x_1, x_2, \dots, x_n)$

→ наше ранее изучавшие моменты / Г оцкнага егун):

$$X \sim U(0, \Theta) \Rightarrow E[X] = \frac{a+b}{2} = \frac{0+\Theta}{2} = \frac{\Theta}{2}$$

→ наше ранее изучавшие моменты / Г оцкнага егун):

* среднестатистическая оценка момента на наблюдениях в изображении

$$\bar{X} = \frac{1}{n} \sum_{j=1}^n x_j$$

→ приравниваем изучавшие и среднестатистические моменты

$$E[X] = \bar{X}$$

$$\frac{\Theta}{2} = \bar{X}$$

$$\Rightarrow \Theta = 2\bar{X}$$

$$\Rightarrow \hat{\Theta}_{MM} = 2\bar{X}$$

+) $X \sim N(\mu, \sigma^2)$, $\vec{x} = (x_1, x_2, \dots, x_n)$ изображение X

→ наше ранее изучавшие моменты

$$X \sim N(\mu, \sigma^2) \Rightarrow E[X] = \mu$$

$$DX = E[X^2] - (E[X])^2 \Rightarrow \sigma^2 = E[X^2] - \mu^2$$

$$E[X^2] = \sigma^2 + \mu^2$$

→ наше ранее изучавшие моменты

$$\bar{X}^{(1)} = \frac{1}{n} \sum_{j=1}^n x_j$$

$$\bar{X}^{(2)} = \frac{1}{n} \sum_{j=1}^n x_j^2$$

→ приравниваем

$$\cdot \quad \mathbb{E}X = \mu = \bar{X} \Rightarrow \hat{\mu} = \bar{X}^{(n)}$$

$$\cdot \quad \mathbb{D}X^2 = \sigma^2 + \mu^2$$

$$\frac{1}{n} \sum_{j=1}^n x_j^2 = \sigma^2 + \bar{X}^2 \Rightarrow \sigma^2 = \frac{1}{n} \sum_{j=1}^n x_j^2 - \bar{X}^2$$

* Гипотеза за М.Н.О. нпв $X \sim N(\mu, \sigma^2)$

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{j=1}^n x_j$$

$\hat{\sigma}^2$ una ghe onym:

$$i) \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2 - \text{кофакт } \mu \text{ е избрано}$$

$$ii) \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2 - \text{кофакт } \mu \text{ не е избрано}$$

↳ гораздни експресии: $L(\vec{X}, \theta) = \prod_{j=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_j - \mu)^2}{2\sigma^2}}, \quad \theta = (\mu, \sigma^2)$

$$L(\vec{X}, \theta) = \ln L(\vec{X}, \theta) = n \ln \frac{1}{\sqrt{2\pi}} - \frac{n}{2} \ln \sigma^2 - \sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2}$$

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{j=1}^n (x_j - \mu) = 0$$

$$\frac{\partial \ln L}{\partial \sigma^2} = \frac{n}{2\sigma^2} + \frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2$$

$$\hat{\mu} = \frac{1}{n} \sum_{j=1}^n x_j = \bar{x}_n$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2$$

* (Баинбо:

* Задф (независимость):

Касбаме, яе $\hat{\theta}$ е независима оценка на θ , ако
 $E[\hat{\theta}(\vec{x})] = \theta$. Когато $\theta = (\theta_1, \dots, \theta_s)$, работнищите са
разделяни равни $E[\hat{\theta}_j(\vec{x})] = \theta_j$, $1 \leq j \leq s$.

Иначе, ако мисълът не е изпълнен, тогава

$|E[\hat{\theta}] - \theta|$ - недостатък (недоволство) грех,

$E[\hat{\theta}] - \theta = 0 \rightarrow$ независимост

* Задф (съвпадение)

Ако $\hat{\theta}(\vec{x}) \xrightarrow[n \rightarrow \infty]{P} \theta$, то $\hat{\theta}$ е съвпадяща оценка

↳ т.е. съвпадащо мисълът \Rightarrow

$\theta \in \mathbb{R} \Rightarrow P(|\hat{\theta}(\vec{x}) - \theta| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$

↳ т.е. мисълът вероятността че $\hat{\theta}$ съм θ , и да е нена
такъгда $\epsilon \rightarrow 0$

Примерът ще

$U(0, \theta) \text{ PDF}$

* Задф (множество съвпадение):

Ако $\hat{\theta}(\vec{x}) \xrightarrow[n \rightarrow \infty]{a.s.} \theta$, то

* Задф: фундаментално на начинанието да приблизи подобие

на резултатите (съществуващо и лъчилният \vec{x} , и т.н.).

$L(\vec{x}, \theta) = \prod_{j=1}^n f(x_j; \theta)$ понятие за залежи на ср. Ген са
нез. и еднакъз разпределени

$$\text{④ } x \sim U(a, b)$$

MM

→ wichtigste Werte

$$\mathbb{E}X = \frac{a+b}{2}$$

$$\mathbb{E}X^2 = \frac{a^2+ab+b^2}{3} \quad \text{um} = \frac{(b-a)^2}{12}$$

→ ermitteln mit

~~$$\bar{X}^{(1)} = \frac{1}{n} \sum_{j=1}^n x_j$$~~

$$\bar{X}^{(2)} = \frac{1}{n} \sum_{j=1}^n x_j^2$$

$$\mathbb{E}X = \bar{X}^{(1)}$$

$$\frac{a+b}{2} = \bar{X}^{(1)} \Rightarrow a+b = 2\bar{X}^{(1)}$$

$$\mathbb{E}X^2 = \bar{X}^{(2)} \Rightarrow \frac{a^2+ab+b^2}{3} = \frac{1}{n} \sum_{j=1}^n x_j^2$$

$$\Rightarrow a+b = 2\bar{X}^{(1)} \Rightarrow b = 2\bar{X}^{(1)} - a$$

zusammenfassend (*) $\frac{a^2+a|2\bar{X}^{(1)}-a| + |2\bar{X}^{(1)}-a|^2}{3} = \frac{1}{n} \sum_{j=1}^n x_j^2$

~~$$\frac{b^2+2ax^{(1)}-a^2}{3} + \cancel{bx^{(1)}} - \cancel{2ax^{(1)}+a^2}$$~~

$$x \sim N(\mu, 1) \quad \vec{x} = (x_1, x_2, \dots, x_n)$$

$$f_{\vec{x}}(\vec{x}, \theta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}}$$

$$L(\vec{x}, \theta) = \prod_{j=1}^n f_{\vec{x}}(x_j, \theta) = \prod_{j=1}^n \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(x_j-\mu)^2}{2}}$$

$$\Rightarrow \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{1}{2} \sum_{j=1}^n (x_j - \mu)^2}$$

$$\ln L = -\frac{n}{2} \ln (2\pi) - \frac{1}{2} \sum_{j=1}^n (x_j - \mu)^2$$

to calculate about μ , more go up with probability

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{2} - \frac{1}{2} \sum_{j=1}^n (x_j - \mu)^2 = -\frac{1}{2} \cdot 2 \sum_{j=1}^n (x_j - \mu) = -\sum_{j=1}^n (x_j - \mu)$$

→ nrepaßt + gave $\rightarrow 0$

$$-\sum_{j=1}^n (x_j - \mu) = 0$$

$$\sum_{j=1}^n x_j = n\mu \Rightarrow \hat{\mu} = \frac{1}{n} \sum_{j=1}^n x_j = \bar{x}_n$$

$$\underline{\hat{\mu} = \bar{x}_n}$$

+ ДОВЕРИТЕЛНИ ИНТЕРВАЛИ

$$P(I_1 \subseteq \Theta \subseteq I_2) = \gamma \rightarrow \text{нбо на доверие}$$

$$\gamma = 0,99, 0,9 \rightarrow 0,95 \text{ by default}$$

- (I_1, I_2) се нарича довериличен интервал, с нбо на доверие.

* Задача: Имаме некоторък модел, искаме да оценим Θ , който описва номина, които имаме. Конструиране на Θ и левата граница на следящия интервал (зависи от избрания), така че вероятността да намерим истина в него, и.е. интервалът (I_1, I_2) г. покрива Θ , да е поне $\gamma (0,95)$

$\rightarrow \Theta$ е фиксиран параметър, а априорната вероятност е в I_1, I_2

\rightarrow Нашето се избира $1-\gamma$ да се слага в левата граница, но пополовина инт.



* Дефиниция (центрирана априорна): Казваме, че $T=T(\vec{x}, \Theta)$ е центрирана априорна, ако:

1) T е монотонна по Θ ($\uparrow \downarrow$)

2) $P(T \leq x) = F_T(x)$ не зависи от Θ

Не функция на Θ , но разпределение и не зависи от Θ)

► Проверка на нулеведа

Нулеведа - идем каква хипотеза (нъврдение), се събира да има някако разпределение $f_{\theta}(x, \theta)$

- идем каква изобража \vec{x}
 - и идем да конструираме някако подмножество на $\mathbb{R}^n \Rightarrow W \subseteq \mathbb{R}^n$, така че
 - ако нашата конструирана реализация \vec{x} | хипотеза като получим в изображата $\vec{x} \in W \Rightarrow$ оцърпим хипотезата
- $\vec{x} \notin W \Rightarrow$ приемаме хипотезата

→ наймен амплекса по аз на Гора

$x, f_{\theta}(x, \theta)$

преди срещу преди
хипотеза

$H_0: \theta = \theta_0$ | нулева хипотеза

→ (да ще получим, че има някакъс работен)

$H_1: \theta = \theta_1$ | альтернативна хипотеза

→ \vec{x}, W ако $\vec{x} \in W$, то отхвърлим H_0 и приемаме H_1

→ Съществува разбирае, че θ е в някакъс интервал, иначе, то не е конструирано априорно

► Грешка от лърби ред: $P(\vec{x} \in W | H_0) = \alpha = \alpha_w$

Всички наблюдения да попаднат в W , т.е. да отхвърлим нулевата хипотеза, при което, че тя е вярна

→ Граница на външната $p_{\text{ог}}$: $P(X \notin W | H_1) = \beta = \beta_W$

Приемаме че търсеният хипотеза, то е върна алигаторна външната

* едината граница може да еднаква на другата

$$W_1 \subseteq W_2 \Rightarrow \omega_{W_1} \leq \omega_{W_2} \Rightarrow \text{имаме} \quad \begin{aligned} \beta_{W_1} &\geq \beta_{W_2} \\ \text{или} & \end{aligned}$$

⇒ α е котир от ръбена граница (което е обратното и е очевидно) β

β не е юлко област граница (разбира се възможният број от 15% , а вероятността им е 15%)

→ W - критичната област за граница на I^{B_u} $p_{\text{ог}}$ α

* Деф(Д.К.О):

Казваме, че $W^* \in \mathbb{R}^n$ е минималната критична област $(D.K.O)$ за фиксираната граница на I^{B_u} $p_{\text{ог}}$ α , ако

$$\beta_{W^*} = \min_{\omega=W^*} \beta_{\omega}$$

→ и.e. фиксирана граница на върху $p_{\text{ог}}$, и търсихме максимална критична област, така че границата на външни $p_{\text{ог}}$ да е минимална

! Търсеният хипотеза е чака до кога то е възможно, да не
е здържано много

→ Разглеждаме просирателната \mathbb{R}^n на L и ако

нашата избранка \vec{x} :

$\vec{x} \in W^* \Rightarrow$ приемаме алигаторната

$\vec{x} \in (W^*)^c = \mathbb{R}^n / W^* \Rightarrow$ приемаме търсения хипотеза

единствено

* Лемата на Нейман-Пирсвът ще ни позволя да видим, как се конструира оптимална бройчика област, така че идеме фиксирана грешка от първи ред "минимална грешка от втори ред", и.e. идеме възможно най-добрия слуга!

* Лема (Нейман-Пирсвът): ^{известно ниво α, и.e. + go < непревъзходи ср. Ben.}

Нека $X \sim f(x|\theta)$, $L(\vec{x}, \theta)$ е избагра \vec{x} .

Ако $\Omega^* \subseteq \mathbb{R}^n$ е к.о. с грешка от първи ред α и

$$\Omega^* \subseteq \{L_1(\vec{x}) \geq k L_0(\vec{x})\}$$

$$(\Omega^*)^c \subseteq \{L_1(\vec{x}) \leq k L_0(\vec{x})\} \text{ за некое } k > 0.$$

Тогава Ω^* е о.к.о за $H_0: \theta = \theta_0$

$$H_1: \theta = \theta_1$$

Г.каза, че ако идеме да конструираме о.к.о., то ще добием да изберем регион от иди ини

→ линейная регрессия

- регресс = Способ оценки среднего

$$Y = \beta_0 + \beta_1 X + \varepsilon \rightarrow \text{регрессия}$$

\downarrow \downarrow
оценивание предсказание

Up next: оценка наименее квадратичных

↳ $\{\varepsilon_1, \dots, \varepsilon_n\}$ - это остатки

↳ $\sum \varepsilon_i = 0$, т.к. сумма всех остатков равна 0

↳ $D\varepsilon_j = \sigma^2$ - остаток ожидается

↳ $\varepsilon_j \sim N(0, \sigma^2)$ - остаток имеет нормальное распределение


→ Two main objectives

- establish if there is a relationship between two variables

- forecast new observations

↳ Can we use what we know about the relationship to forecast unobserved values?

* We call it "linear" because it equation represents a straight line in b-dimensional plot



→ the linear regression is going to draw a line that minimizes this errors

$$y = \beta_0 + \beta_1 x + \varepsilon$$

y - dependent variable

x - independent variable

- β_0 is the constant or intercept
 - β_1 is x's slope or coefficient
 - ϵ is the error term
- Confidence Intervals

↳ overall we're going to choose models with greater value for R-squared

↳ R-squared = $1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

↳ $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{137}{640} = 0.787$

↳ $\hat{y} = 2.0 + 0.5x$

↳ But what if we want to add another variable? (e.g. x_2)

↳ $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2$

↳ If we do this, we'll have to recompute the R-squared.

↳ $\hat{y} = 2.0 + 0.5x_1 + 0.2x_2$

↳ $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{137}{640} = 0.787$

↳ $\hat{y} = 2.0 + 0.5x_1 + 0.2x_2$

↳ $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{137}{640} = 0.787$

↳ $\hat{y} = 2.0 + 0.5x_1 + 0.2x_2$

↳ $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{137}{640} = 0.787$

* д-р на максималто нийгэеногодын

$$x \sim N(\mu, \sigma^2), \vec{x}; \theta \in \mathbb{H} = \mathbb{R} \times \mathbb{R}^+ \quad \text{параметр}$$

$$L(\vec{x}, \theta) = (2\pi)^{-\frac{n}{2}} |\sigma^2|^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu)^2}$$

* логарифмийн е равнигын д-р

$$\text{т.б. яланхилбэрд цэвэртэй нь } \frac{\partial \ln L}{\partial \theta} = 0 \quad \begin{array}{l} \rightarrow \text{шарын } \theta \text{-ийн ишиг санал} \\ \text{тодохонт хамаатнуулж} \end{array}$$

* Т.б. пагнүү: \vec{x} е ишбагра (n -т. б. э. р. с. н. б.н.) на x танд $x \sim N(\mu, \sigma^2)$.

$$\text{Торба } \mu \text{ е } \bar{x}_n = \frac{1}{n} \sum_{j=1}^n x_j$$

↓
средний
арифметичний

$$\text{М.Н.О., за } \sigma^2 \text{ е}$$

$$\text{а)} \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2 \text{ або } \mu \text{ е зүйл}$$

$$\text{б)} \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2 \text{ або } (\mu \text{ не е зүйл})$$

Бичих барто, нөхөн ишиг дахиу шарын
нийтийн магадгүй за гүнчлэгийн шарын не

$$\text{г-бо: } \ln L(\vec{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \sum_{j=1}^n \frac{(x_j - \mu)^2}{2\sigma^2} \quad \theta = (\mu, \sigma^2)$$

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{j=1}^n (x_j - \mu) = 0 \Rightarrow \mu = \bar{x}_n$$

но μ

Бичих нийтийн оюутнаа та μ
Бичих е срэгийн арифметичний

$$\frac{\partial \ln L}{\partial^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{j=1}^n (x_j - \mu)^2 = 0$$

$\mu = \bar{x}_n$

↳ две едници
но σ^2

→ Ако знаям $\mu \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2$

но ако не знаям $\mu \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2$

↳ Ако е само една неизвестна параметър, решаване само

$\frac{\partial \ln L}{\partial^2}$ и получаване $\hat{\sigma}^2 \rightarrow$ юнкова оценка за дисперсия

↳ Ако не знаям и гъвката параметри, решаване гъвките уравнения (произвдота по параметър, произвдота по параметър)

→ М.Л. работи заедно със знаящо како най-много коригирана вероятност

→ \vec{X} , имат n -бо със хипотеза H за линейността на X ,
знаящо и забога е \vec{X} , за брака хипотеза имаме линейност
 $f_{X|H}(x), h \in H$

Знаящо, че $h + t \in H$ работи, т.e. $f_{X|H}(x) = f(x, h)$
Линейността, т.e. хипотеза

$$H = \mathbb{R} \times \mathbb{R}^+ \quad h = (\mu, \sigma^2), \quad X \sim N(\mu, \sigma^2)$$

$$h = \vec{z}$$

$$h_t = (0, 1)$$

може да е 0 или 1, ако
заявите също съдействат
нормална сълб.

↓
заявите хипотезите не са
нужни да са изпълнени с числата
или бесконечни или много

* Ентропия на Y

$$Ent(Y) = \int \log f_Y(y) f_Y(y) dy$$

което съдържа да бъдате кинове, които са близки до нашите, те ентропията да са близки го

$$Ent(X) = \int \log f_{X,h}(y) f_{X,h}(y) dy$$

$$\Rightarrow \log f(x, h), \quad h \neq h^*$$

||

$$\log f(x, h^*)$$

$$\hookrightarrow h \in H; \frac{\ln L(\vec{x}, h)}{n} \xrightarrow{n \rightarrow \infty} \log f(x, h)$$

$$h^* \in H; \frac{\ln L(\vec{x}, h^*)}{n} \xrightarrow{n \rightarrow \infty} Ent(X)$$

!→ максимум на горната, т.е. юе се съотврдиме към най-искитаните

граници т.е при много кинове юе се съотврдиме към искитаните кинове

Метод на моментите

→ При М.М.А избраният ефект, който максимизира съблизността между тоци

и тук при М.М. не е необходимо да изберем съблизността

$$X, F(x, \theta), \vec{x}$$

$$\hat{X} \stackrel{\text{def.}}{=} \lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n x_i}{n}, \quad \text{да допуснем т.е. } EY = \mu(\theta), \text{ ако } Y \text{ има}$$

$\mu(\theta_0)$

тогава убележаваме данните
ще се съотврдиме към искитаните
значения т.е. $\mu(\theta_0)$

$$\bar{X}_n^{(1)} := \frac{\sum_{j=1}^n X_j}{n} = M(\theta) \Rightarrow \hat{\theta} = \mu^{-1}(\bar{X}_n^{(1)})$$

+ Задача: Найти X , $F(X, \theta)$, $\theta = (\theta_1, \dots, \theta_s)$ и $\hat{\theta}$.

последовательность $X_n^{(ij)} = \frac{\sum_{k=1}^n X_k^{(ij)}}{n} \xrightarrow[n \rightarrow \infty]{} f(x)$

Решение на уравнения $f(x) = X_n^{(j)}, 1 \leq j \leq s$
 $\mu'(\theta)$

$$\hat{\theta} = \mu^{-1}(X_n^{(1)}) \quad , \quad X_n^{(1)} = (X_n^{(1)}, \dots, X_n^{(s)})$$

се называет оценка по М.М.

* Всеки един от тези моменти, да като, j на брой е някаква функция на найизбраният или параметър

Пр. при нормалното, лъчътът момент е просто M

④ $X \in U(0, \theta)$, $\theta > 0$, \bar{X}

$$X_n^{(1)} = \frac{\sum_{j=1}^n X_j}{n} = \frac{\theta}{2} = f(x) \Rightarrow \hat{\theta} = 2X_n^{(1)}$$

$$X_n^{(1)} = \frac{\hat{\theta}}{2} \xrightarrow[n \rightarrow \infty]{\text{n.c.}} f(x) = \frac{\theta_0}{2} \Rightarrow \hat{\theta} \rightarrow \theta_0$$

ошибки

М.п.д.

$$\hat{\theta} = \max(x_i) \neq 2x_n^{(1)}$$

⊕ $X \sim N(\mu, \sigma^2)$

$$\begin{aligned} E[X] &= \mu = x_n^{(1)} = \frac{\sum_{j=1}^n x_j}{n} \Rightarrow \hat{\mu} = x_n^{(1)} \equiv \text{оценка по М.п.д.} \\ E[X^2] &= \sigma^2 + \mu^2 = \frac{\sum_{j=1}^n x_j^2}{n} \Rightarrow \hat{\sigma}^2 = \frac{\sum_{j=1}^n x_j^2}{n} - (x_n^{(1)})^2 = x_n^{(2)} - (x_n^{(1)})^2 \end{aligned}$$

$x_n^{(2)}$
второй момент
е среднo арифметичнo
оn варинт силента

\equiv оценка по М.п.д.

* Свойства на моментни оценки

a) Независимост

$\hat{\theta}_0 = E[\hat{\theta} | \vec{x})$ → и.е. Не налиме никаква оценка, която съвпада със значението на данните, или която има исклучително грешка в средната, която не е оценка на оценка

⊕ $X \sim N(\mu, \sigma^2)$ $\hat{\mu} = x_n^{(1)}$

$$E[\hat{\mu}] = E\left[\frac{1}{n} \sum_{j=1}^n x_j\right] = \mu$$

значи това как
че тя съвпада със средната
изчисление

• Ако μ е известно, а не знаем σ^2 , то

$$E[\hat{\sigma}^2] = E\left[\frac{1}{n} \sum_{j=1}^n (x_j - \mu)^2\right] = \frac{1}{n} \sum_{j=1}^n E[(x_j - \mu)^2] = \frac{1}{n} \sum_{j=1}^n D x_j = \sigma^2$$

• Тогава знаем μ , $\hat{\sigma}^2$, което съвсем изпълнява независимост

оценка на неизвестния параметър σ^2

ко Ako mu б са неизвестни, ид

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x}_n)^2 = \frac{1}{n} \sum_{j=1}^n x_j^2 - \left(\frac{1}{n} \sum_{j=1}^n x_j \right)^2 = \bar{x}_n^{(2)} - (\bar{x}_n^{(1)})^2$$

$$\hat{\sigma}^2 = \mathbb{E} \bar{x}_n^{(2)} - \mathbb{E}(\bar{x}_n^{(1)})^2 \Leftrightarrow$$

\downarrow
че то да е
съществуващата
 σ^2 ,
което е заг
ногена

\downarrow
огледането на
шози израз е в пъти
по втория момент на x ,
затова не са еднакви
разпределени

$$\mathbb{E} \hat{\sigma}^2 = \left(\frac{n-1}{n} \right) \sigma^2 \approx 1, \sigma^2$$

$$\Rightarrow \mathbb{E} \bar{x}_1^2 - \frac{1}{n^2} \mathbb{E} \left(\sum_{j=1}^n x_j^2 + \sum_{i \neq j} x_i x_j \right) =$$

\downarrow
при гонки
избегват

$$= \mathbb{E} \bar{x}_1^2 - \frac{1}{n^2} \mathbb{E} \bar{x}_1^2 - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E} x_i x_j =$$

$$= \left(\frac{n-1}{n} \right) \mathbb{E} \bar{x}_1^2 - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E} x_i \mathbb{E} x_j = \left(\frac{n-1}{n} \right) \mathbb{E} \bar{x}_1^2 - \frac{1 \cdot M}{n^2} \cdot \frac{1}{n-1} =$$

$$= \left(\frac{n-1}{n} \right) \left(\mathbb{E} \bar{x}_1^2 - (\mathbb{E} \bar{x}_1)^2 \right) = \frac{n-1}{n} \sigma^2$$

\downarrow
 σ^2

$\hat{\sigma}^2$ е неизменената оцетка на σ^2 , затова идно що
огледале е $\left(\frac{n-1}{n} \right) \sigma^2$

ко юба се твърди асимптотично неизвестата оцетка, ~~които~~ е
е затова не е идно равна на σ^2 , но за голко n , ю е
добра до начинско ю σ

δ) (свойства оценки на выборка оценка)

* Def: $X \sim F(x, \Theta)$, $\Theta = (\theta_1, \dots, \theta_s)$, \vec{X} , то назовем, что $\hat{\Theta} = \Theta(\vec{X})$ есть свойства оценка на Θ , $\hat{\Theta} \xrightarrow[n \rightarrow \infty]{P} \Theta$ или эквивалентно $\hat{\theta}_j \xrightarrow[n \rightarrow \infty]{P} \theta_j$, $\forall 1 \leq j \leq s$

* Важна една изредба да не съдим по бородитост, тъй като искаме

о

назовем, че $\hat{\Theta}$ е азимут свойства, ако $\hat{\Theta} \xrightarrow[n \rightarrow \infty]{a.s.} \Theta$ или эквивалентно $\hat{\theta}_j \xrightarrow[n \rightarrow \infty]{a.s.} \theta_j$, $\forall 1 \leq j \leq s$

$$\textcircled{A} \quad X \sim N(\mu, \sigma^2) \text{ и } \hat{\mu} = \bar{x}_n \xrightarrow[n \rightarrow \infty]{\text{УЗГЧ}} \mu \quad x_i = y_i$$

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 = \frac{1}{n} y_n^{(2)} - \left| \frac{y_n^{(1)}}{2} \right|^2 = \\ &= \frac{\sum_{i=1}^n x_i^2}{n} - \left| \frac{\sum_{i=1}^n x_i}{n} \right|^2 \end{aligned}$$

$$\xrightarrow[n \rightarrow \infty]{\text{УЗГЧ}} \hat{\sigma}^2 = \bar{x}_1^2 - \mu^2 = \sigma^2 + \mu^2 - \mu^2 = \sigma^2$$

