

1.

1.) Здефинирайте елементарно на вероятностно пространство

↳ Нека Ω е мн.-ост елементарни събития, \mathcal{F} е σ -алгебра и $P: \mathcal{F} \rightarrow [0, 1]$ е вероятностна ф.-я. Тогава наредената тройка (Ω, \mathcal{F}, P) се нарича вероятностно пространство

2.) Въведете понятието пораняваща функция

↳ Нека X е числова, неотрицателна, дискретна сл. величина, във вероятностно пространство $V = (\Omega, \mathcal{F}, P)$, като $X: \Omega \rightarrow N = \{0, 1, 2, \dots\}$, тогава

$$g_X(s) = E e^{sX} = \sum_{k=0}^{\infty} s^k P(X=k) = \sum_{k=0}^{\infty} s^k p_k, \text{ за } |s| \leq 1.$$

се нарича пораняваща функция.

3.) Формулирайте и докажете теоремата на Пуассон

↳ Нека $X_n \sim \text{Bin}(n, p_n)$, $\forall n \geq 1$. Нека е в сила, че $p_n = \frac{U_n}{n} + \frac{\lambda}{n}$, където $\lim_{n \rightarrow \infty} U_n = 0$ и $\lambda > 0$. Тогава

$$P(X_n = k) \xrightarrow{n \rightarrow \infty} P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \geq 0$$

$$* \quad X_n \xrightarrow[n \rightarrow \infty]{d} X \sim \text{Poi}(\lambda)$$

$$\text{доказателство: } U_n := 0 \Rightarrow p_n = \frac{\lambda}{n} \Rightarrow q_n = 1 - p_n = 1 - \frac{\lambda}{n}$$

$$g_{X_n}(s) = (q_n + p_n s)^n = \left(1 - \frac{\lambda}{n} + \frac{\lambda}{n} s\right)^n = \left(1 + \frac{\lambda(s-1)}{n}\right)^n$$

$$\downarrow$$

$$g_X(s) = e^{\lambda(s-1)}$$

$$= \left(1 + \frac{\lambda(s-1)}{n}\right)^n = e^{\lambda(s-1)}$$

$$\downarrow$$

$$e^{\lambda(s-1)}$$

2. 1.) формулируйте и докажите неравенство Чебышева

$$\hookrightarrow P(|X - EX| > \varepsilon) \leq \frac{DX}{\varepsilon^2}, \quad \forall \varepsilon > 0$$

\hookrightarrow доказательство следует напрямую из неравенства Маркова, если применим $Y = (X - EX)^2$ и $a = \varepsilon^2$

$$\Rightarrow P(|X - EX|^2 > \varepsilon^2) \leq \frac{E[(X - EX)^2]}{\varepsilon^2} = \frac{DX}{\varepsilon^2}$$

$P(|X - EX| > \varepsilon)$ \hookrightarrow эти свойства (следствие) из неравенства Маркова

2.) формулируйте и докажите при условии дисперсия слабая закон за большие числа

\hookrightarrow Если имеем рядующийся из одинаково распределенных и независимых (i.i.d.) случайных величин $(X_i)_{i \geq 1}$ с ожиданиями EX_i . Тогда, то для X выполняется ЗГЧ (слаб.) ако:

$$\frac{\sum_{i=1}^n (X_i - EX_i)}{n} \xrightarrow[n \rightarrow \infty]{P} 0$$

\rightarrow За X_1, \dots, X_n нез. и одн. разн с $DX_i < \infty$ и верен (слаб.) ЗГЧ:

$$\frac{\sum_{i=1}^n (X_i - EX_i)}{n} \xrightarrow[n \rightarrow \infty]{P} 0 \Leftrightarrow \frac{\sum_{i=1}^n X_i}{n} \xrightarrow[n \rightarrow \infty]{P} EX_1$$

доказателство:

$$S_n = \sum_{i=1}^n \bar{x}_i \Rightarrow \mathbb{E} S_n = n \cdot \mathbb{E} X_1$$

$DS_n = n \cdot DX_1 \rightarrow$ по теорема на независими и еднакви разпределения

искам да докажем, че:

$$\frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{P} \mathbb{E} X_1$$

Нека $\varepsilon > 0$

$$\begin{aligned} P\left(\left|\frac{S_n}{n} - \mathbb{E} X_1\right| > \varepsilon\right) &\stackrel{\text{прилагаме Чебушев}}{\leq} \frac{D\left(\frac{S_n}{n}\right)}{\varepsilon^2} = \frac{\frac{1}{n^2} DS_n}{\varepsilon^2} = \frac{\frac{1}{n} DX_1}{\varepsilon^2} = \\ &= \frac{1}{n} \underbrace{\left[\frac{DX_1}{\varepsilon^2}\right]}_{\text{const}} \end{aligned}$$

$$\Rightarrow \text{при } \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - \mathbb{E} X_1\right| > \varepsilon\right) \leq \lim_{n \rightarrow \infty} \frac{1}{n} \left[\frac{DX_1}{\varepsilon^2}\right] = 0$$

$$\Rightarrow \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{P} \mathbb{E} X_1$$

3] Нека $(X_n)_{n \geq 1}$ е редуциран сл. вел. Нека $(\lambda_n)_{n \geq 1}$ е редуциран сл. вел. с $\lambda_n \sim \text{Exp}(\lambda_n)$, $\lambda_n > 0$, $n \geq 1$.

1) Чрез $(X_n)_{n \geq 1}$ въведем $X_n \xrightarrow{d} X$, когато X е някаква случайна величина

кажем, че редуциран X_n клони към сл. вел. X по разпределение, ако за всяка непрекъсната на непрекъснатост $F_X(x) := P(X \leq x)$ е вярно, че:

$$F_{X_n}(x) = P(X_n \leq x) \xrightarrow[n \rightarrow \infty]{d} P(X \leq x) = F_X(x) \text{ и имам}$$

$$X_n \xrightarrow[n \rightarrow \infty]{d} X$$

.) Намерете функцията на моментите на e_1 и
чрез нея намерете $\Phi[e_1]$ и $\Phi[e_1^2]$

$$e_n \sim \text{Exp}(\lambda) \Rightarrow n=1 \Rightarrow e_1 \sim \text{Exp}(\lambda)$$

$$M_X(t) = \mathbb{E} e^{tX} = \int_{-\infty}^{\infty} e^{tx} \cdot f_X(x) dx$$

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{иначе} \end{cases}$$

$$\begin{aligned} \Rightarrow M_X(t) &= \int_0^{\infty} e^{tx} \cdot e^{-\lambda x} \cdot \lambda dx = \lambda \int_0^{\infty} e^{x(t-\lambda)} dx = \\ &= \lambda \cdot \frac{1}{t-\lambda} \left[e^{x(t-\lambda)} \right]_0^{\infty} = \lambda \cdot \frac{1}{t-\lambda} \cdot 0 - 1 = \frac{\lambda}{\lambda-t}, t < \lambda \end{aligned}$$

$$\hookrightarrow \frac{d^k}{dt^k} M_X(t) \Big|_{t=0} = \mathbb{E} X^k$$

$$\rightarrow \frac{d}{dt} M_X(t) \Big|_{t=0} = \frac{d}{dt} \frac{\lambda}{\lambda-t} = \frac{\lambda}{(\lambda-t)^2} \Big|_{t=0} = \frac{1}{\lambda^2} = \frac{1}{\lambda}$$

$$\begin{aligned} \rightarrow \frac{d^2}{dt^2} M_X(t) \Big|_{t=0} &= \frac{d^2}{dt^2} \frac{\lambda}{\lambda-t} = \frac{d}{dt} \frac{\lambda}{(\lambda-t)^2} = \frac{2\lambda}{(\lambda-t)^3} \Big|_{t=0} = \\ &= \frac{2\lambda}{\lambda^3} = \frac{2}{\lambda^2} \end{aligned}$$

5. 1.) Запише дефиниция за оценка по метода на моментите

Нека X има функция на ~~плотност~~ разпределение

$f_X(\vec{x}; \theta)$, \vec{x} е изводка над X ,

$\theta[X^k] = M^{(k)}(\theta) \rightarrow$ теоретичните моменти, $k=1, 2, \dots$

$\bar{X}^{(k)} = \frac{1}{n} \sum_{i=1}^n x_i^k \rightarrow$ емпиричните моменти, $k=1, 2, \dots$

и $\theta = (\theta_1, \dots, \theta_s)$. Тогово решение на системата

$$M^{(k)}(\theta) = \bar{X}^{(k)}, \text{ за } k=1, \dots, s$$

θ се нарича оценка по М.М.

2.) Нека $X \sim \text{Poi}(1440\lambda)$ и $Y \sim \text{Poi}(1440\mu)$, където λ и $\mu > 0$

X и Y се моделира броят на катографите

свойства в Европа и Америка. Нека $\vec{X} = (X_1, \dots, X_n)$

$\vec{Y} = (Y_1, \dots, Y_n)$ са независими наблюдения над X и Y

$(X_1, X_2, \dots, X_n, Y_1, \dots, Y_n)$ са независими в съвкупност,

Нека $\vec{Z} = \vec{X} + \vec{Y}$

а) Предложете оценка по метода на моментите за λ .

$$EX = 1440\lambda$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\Rightarrow EX \approx \bar{X}$$

$$1440\lambda \approx \bar{X}$$

$$\lambda \approx \frac{\bar{X}}{1440} \Rightarrow \lambda = \frac{1}{1440} \cdot \frac{1}{n} \sum_{i=1}^n x_i$$

λ οὐ α) ε' добра и зашо?

$$\hat{\lambda}_{MM} = \frac{1}{1400} \cdot \frac{1}{n} \sum_{i=1}^n x_i, \text{ корані } n=2, \text{ одержано авто:}$$

$$\lambda_{MM}^{\wedge} = \frac{1}{1400} \cdot \frac{1}{2} |t_1 + t_2|$$

В оценката, базирана на две наблюдения, не е особено добра поради следните причини:

- висока променливост и нештабилност:
малкият брой наблюдения води до значителен
случаен променливост, която може да
отклонява оценката далеч от истинската
стойност на λ .
- неслучайна и ниска шотност:
малката извадка увеличава неслучайната
и намалява шотността на оценката.

☞ За по-надеждна оценка на Л, би било по-добре да чнаме повече благодарения.

→) Ако разполагаме със $\vec{z} = (z_1, z_2)$, то намерете оценки за λ, μ и аргументирано дискутирайте тяхното качество

$$\begin{aligned} X &\sim \text{Poi}(1400\lambda) \\ Y &\sim \text{Poi}(1400\mu) \\ \Rightarrow Z = X + Y &\Rightarrow Z \sim \text{Poi}(1400\lambda + 1400\mu) = \\ &\sim \text{Poi}(1400(\lambda + \mu)) \end{aligned}$$

$$\hookrightarrow E Z = 1400(\lambda + \mu)$$

$$\bar{z} = \frac{1}{2}(z_1 + z_2)$$

ММ

→ приравняване теоретичните към емпиричните моменти

$$1400(\lambda + \mu) \approx \frac{1}{2}(z_1 + z_2)$$

$$\Rightarrow (\hat{\lambda} + \hat{\mu})_{\text{ММ}} = \frac{1}{2 \cdot 1400}(z_1 + z_2)$$

$$\Rightarrow \text{ако искаме до тук намерим очевидно} \quad \begin{aligned} \hat{\lambda}_{\text{ММ}} &= \frac{\hat{\lambda} + \hat{\mu}}{2} \\ \hat{\mu}_{\text{ММ}} &= \frac{\hat{\lambda} + \hat{\mu}}{2} \end{aligned} \quad ?$$

$$\Rightarrow L(\vec{z}, \lambda, \mu) = \prod_{i=1}^2 \frac{e^{-1400(\lambda + \mu)} (1400(\lambda + \mu))^{z_i}}{z_i!} \rightarrow \text{ф-я не е провоторна}$$

→ логаритмична ф-я на провоторност

$$\begin{aligned} \ln L(\vec{z}, \lambda, \mu) &= \sum_{i=1}^2 [-1400(\lambda + \mu) + z_i \ln(1400(\lambda + \mu)) - \ln(z_i!)] = \\ &= -2 \cdot 1400(\lambda + \mu) + (z_1 + z_2) \ln(1400(\lambda + \mu)) - \text{const} \end{aligned}$$

$$\begin{aligned} \rightarrow \frac{\partial \ln L}{\partial (\lambda + \mu)} &= -2 \cdot 1400 + \frac{z_1 + z_2}{1400(\lambda + \mu)} \cdot 1400 = 0 \quad \text{MLE} \\ 1400(\lambda + \mu) &= \frac{z_1 + z_2}{2} \Rightarrow \hat{\lambda} + \hat{\mu}_{\text{MLE}} = \frac{1}{2 \cdot 1400}(z_1 + z_2) \end{aligned}$$

⇒ При малък брой на благотения, оценките могат
не са абилни и некорни

■ Нека $X \sim \text{Exp}(\lambda)$, $\lambda > 0$ и имаме на благотения
 $\vec{x} = (x_1, x_2, \dots, x_n)$. В контекста на изпитване на
хипотези разгледайте въпросите:

1.) Дефинирайте грешка от първи и грешка от
втори род

↳ Грешка от първи род: $P(\vec{X} \in \omega | H_0) = \alpha = \alpha_\omega$

⇒ нашите наблюдения (\vec{x}) да попаднат в ω ,
т.е. да отхвърлим нулевата хипотеза, при
положение, че тя е вярна

↳ Грешка от втори род: $P(\vec{X} \notin \omega | H_1) = \beta = \beta_\omega$

⇒ приемаме нулевата хипотеза, но е вярна
алтернативната

2.) Дефинирайте оптимална критична област при
зададена грешка от първи род

↳ Казваме, че $\omega^* \in \mathbb{R}^n$ е оптимална критична
област (О.К.О) за фиксирана грешка от първи
род, ако $\beta_{\omega^*} = \min \beta_\omega$

$$\alpha_\omega = \alpha_{\omega^*} = \alpha$$

Зележка

⇒ т.е. фиксираме грешка от първи род и
избираме такава критична област, която грешката
от втори род да е минимална

3.) формулирайте лемата на Хейман-Лирсън

Нека $X, \neq x(x, \theta), L(\vec{x}, \theta)$ и извадка \vec{x} ,

Ако $w^* \in \mathbb{R}^n$ е к.о. с грешка от първи ред α и

$$w^* \in \{L_1(\vec{x}) \pm \kappa L_0(\vec{x})\}$$

$$(w^*)^c \subseteq \{L_1(\vec{x}) \pm \kappa L_0(\vec{x})\} \quad , \text{ за някоя } \kappa > 0.$$

Тогато w^* е о.к.о. за $H_0: \theta = \theta_0$
 $H_1: \theta = \theta_1$.

